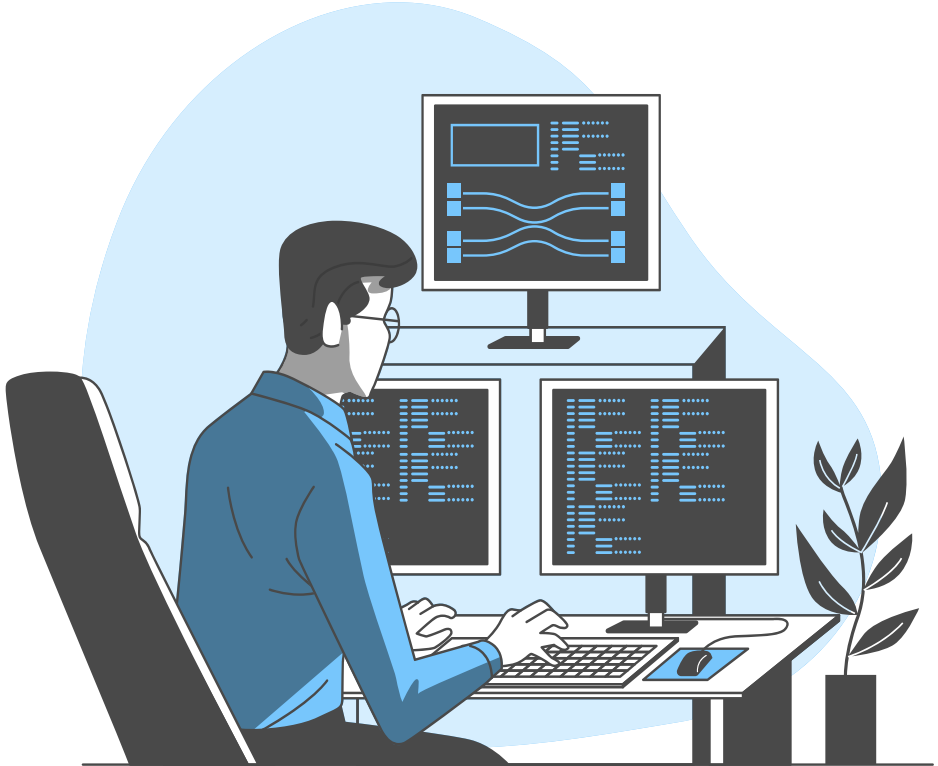

Ingeniería Software

Fundamentos para Ciencia de Datos

Cual es el producto que entrega un científico de datos?

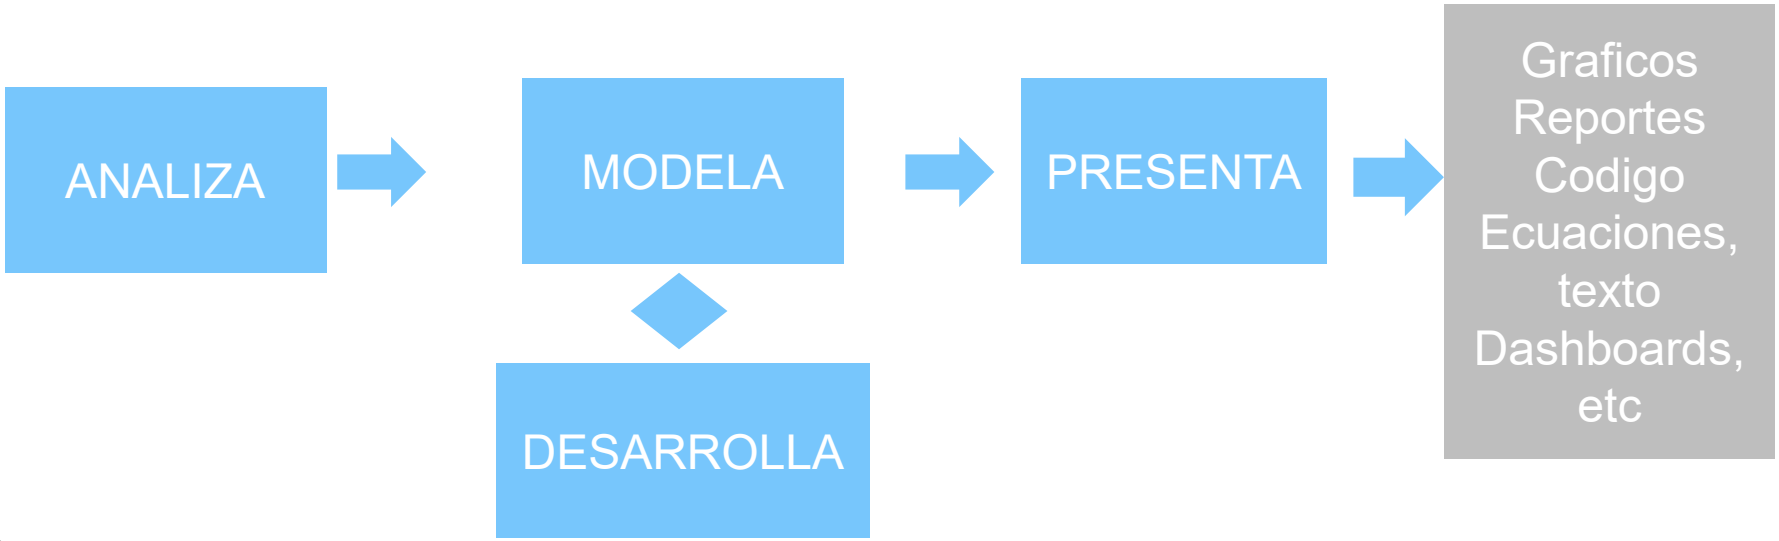

Herramientas comunes

NOTEBOOKS

JUPYTER LABS

De notebooks a módulos productivos

Los notebooks funcionan como laboratorios para experimentación rápida.

En producción, el código debe organizarse en módulos reutilizables y bien estructurados. Es fundamental que los notebooks consuman el código, no lo definan, para facilitar la mantenibilidad y colaboración eficaz.

01

Introducción a la Ingeniería de Software en Ciencia de Datos

Introducción

La ingeniería de software en ciencia de datos se enfoca en transformar experimentos en productos robustos. No basta con entrenar modelos, es esencial construir software **mantenible** y **escalable** que facilite su operación continua y confiable. Este enfoque asegura reproducibilidad y colaboración efectiva en proyectos de datos.

Definición y objetivos

La ingeniería de software es la disciplina que permite construir sistemas de software **mantenibles**, **escalables** y **reproducibles**. En ciencia de datos, su objetivo no se limita a desarrollar modelos, sino a operarlos eficazmente, garantizando que los sistemas funcionen de manera continua y sean fáciles de mantener en producción.

Problemas comunes en Productos de Data Science

Muchos modelos funcionan pero enfrentan dificultades para mantenerse y reutilizarse. Estos problemas no son matemáticos, sino de software: código desordenado, notebooks gigantes, variables globales y rutas fijas dificultan la colaboración y escalabilidad, lo que genera deuda técnica y reduce la efectividad del equipo.

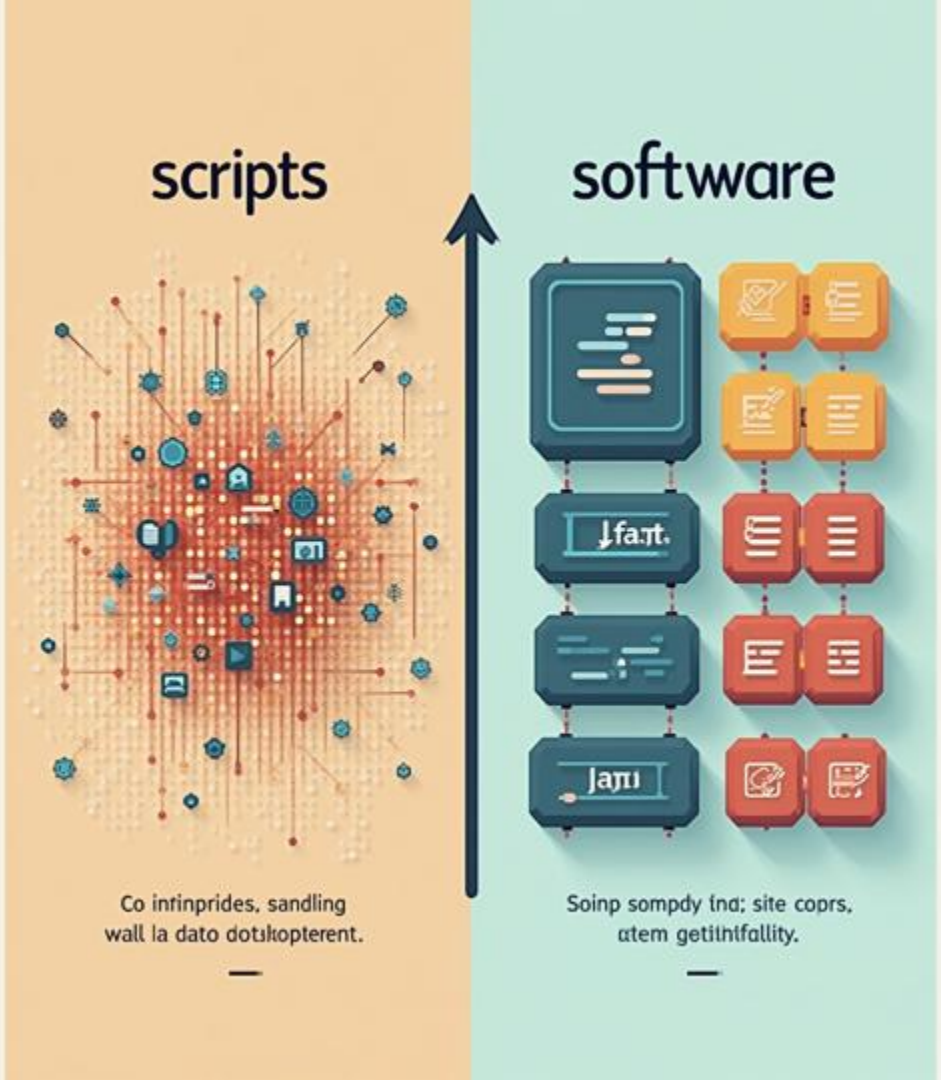

Diferencias entre scripts y software

Los *scripts* son rápidos y desordenados, ideales para la exploración inicial de datos. Sin embargo, carecen de estructura y mantenimiento.

El *software* es modular, reutilizable y preparado para producción, lo que permite un desarrollo más sostenible y escalable. La transición del script al software es clave para transformar experimentos en productos confiables.

01

Desarrollo y despliegue de proyectos de datos

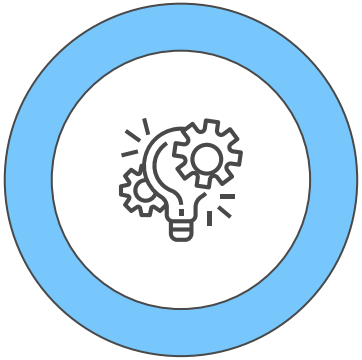

Ciclo de vida de proyectos en Data Science

Los proyectos de datos atraviesan varias etapas: identificación del problema, exploración, prototipado, industrialización, despliegue y mantenimiento.

Este ciclo es **iterativo**, no lineal, y requiere constante revisión para garantizar que los modelos evolucionen y se mantengan útiles en producción.

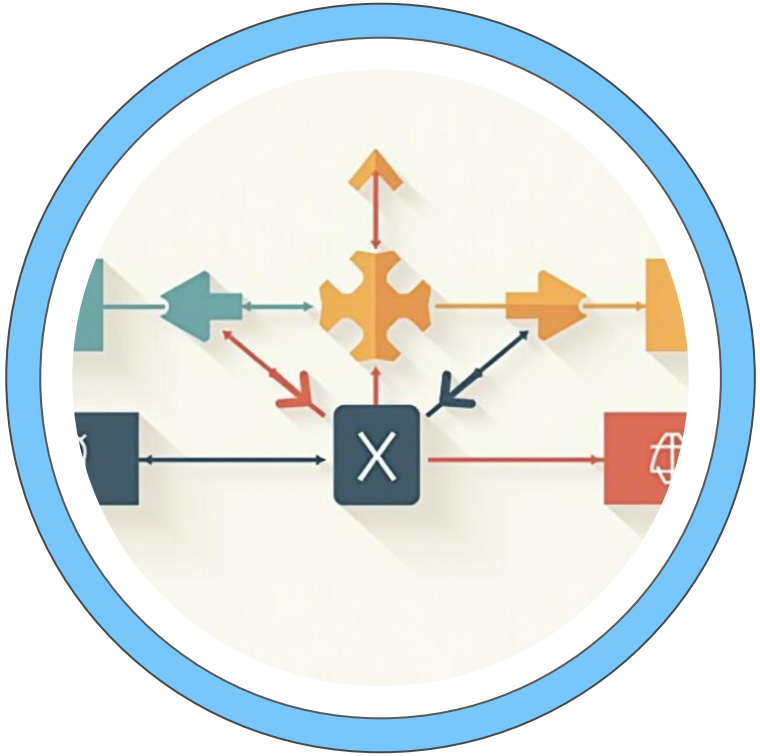

Conceptos clave para código mantenible

El diseño debe buscar **modularidad**, con alta cohesión y bajo acoplamiento entre componentes.

Esto reduce dependencias, mejora la flexibilidad y facilita el mantenimiento. Evitar código duplicado y mantener la claridad son prácticas esenciales para minimizar la deuda técnica.

Conclusiones

La ingeniería de software aplicada a ciencia de datos transforma modelos experimentales en productos robustos y sostenibles.

Adoptar prácticas profesionales reduce errores, facilita el trabajo en equipo y asegura modelos reproducibles con menor deuda técnica, permitiendo que los proyectos de datos sean escalables y mantenibles a largo plazo.